

ΠΑΝΕΠΙΣΤΗΜΙΟ ΙΩΑΝΝΙΝΩΝ

ΤΜΗΜΑ ΜΗΧ. Η/Υ & ΠΛΗΡΟΦΟΡΙΚΗΣ

ΥΠΟΛΟΓΙΣΤΙΚΗ ΝΟΗΜΟΣΥΝΗ

2^Η ΑΣΚΗΣΗ ΓΙΑ ΤΟ ΑΚΑΔΗΜΑΪΚΟ
ΕΤΟΣ 2024-2025

ΟΜΑΔΑ 5380-5226

ΙΩΑΝΝΗΣ ΦΙΛΛΗΣ, ΑΜ:5380

ΚΩΝΣΤΑΝΤΙΝΟΣ ΖΩΗΣ, ΑΜ:5226

ΤΕΛΙΚΗ ΑΝΑΦΟΡΑ

ΙΑΝΟΥΑΡΙΟΣ 2025

1 ΕΙΣΑΓΩΓΗ

Σε αυτή την άσκηση ζητείται να υλοποιήσουμε ένα πρόγραμμα για το πρόβλημα ομαδοποίησης 8 ομάδων με τον αλγόριθμο k-means. Παρατηρούμε τη συμπεριφορά του αλγορίθμου για διάφορες τιμές του αριθμού των ομάδων.

2 ΠΛΗΡΟΦΟΡΙΕΣ ΓΙΑ ΤΗΝ ΥΛΟΠΟΙΗΣΗ

Η υλοποίηση του αλγορίθμου έγινε στο αρχείο **P0.java**. Στον πίνακα **points** αποθηκεύουμε όλα τα σημεία (x1,x2) από το αρχείο clustering_data.txt με την μέθοδο **loadDataSet()**. Τα κέντρα αποθηκεύονται στον πίνακα **centroids** και αρχικοποιούνται με τυχαίες τιμές από τα παραδείγματα στην μέθοδο **setStartingCentroids()**. Η κύρια δουλειά γίνεται στη μέθοδο **kmeans()**. Σε κάθε loop αποθηκεύουμε τις ομάδες στον πίνακα **clusters** που είναι μια λίστα από λίστες πινάκων των σημείων, έτσι ώστε κάθε index αυτής της λίστας να μας δίνει και μια ομάδα. Στη συνέχεια πρέπει να βάλουμε κάθε παράδειγμα στην κατάλληλη ομάδα, δηλαδή στην κατάλληλη θέση της λίστας. Αυτό γίνεται με την μέθοδο **findNearestCluster()** που υπολογίζει και συγκρίνει τις Ευκλείδειες αποστάσεις του σημείου από το κάθε κέντρο. Η Ευκλείδεια απόσταση υπολογίζεται από την **calculateEuclidianDistance()**. Μετά, υπολογίζουμε τα νέα κέντρα με τη μέθοδο **calculateNewCentroid()**, η οποία βρίσκει τη μέση τιμή των στοιχείων σε μία ομάδα, δηλαδή στην κατάλληλη λίστα της **clusters**. Για να βγούμε από τον βρόγχο while και να τερματίσει ο αλγόριθμος πρέπει η μεταβλητή **centroidsChanged** να γίνει false. Αν ένα από τα κέντρα έχει αλλάξει τη θέτουμε ξανά true και ο αλγόριθμος συνεχίζει. Η **calculateClusteringError()** υπολογίζει το σφάλμα ομαδοποίησης. Τέλος στη main υπολογίζουμε και τυπώνουμε το σφάλμα για 20 επαναλήψεις και αποθηκεύουμε τα κέντρα για το μικρότερο σφάλμα σε ένα αρχείο με τη μέθοδο **saveCentroidsToFile()**.

Για να τρέξει το πρόγραμμα, αρχικά το κάνουμε compile με την εντολή **javac P0.java** και στη συνέχεια το εκτελούμε γράφοντας **java P0**

Το πρόγραμμα ClusteringDataGeneration.java χρησιμοποιήθηκε για την δημιουργία και την αποθήκευση των τυχαίων σημείων στο αρχείο clustering_data.txt.

3 ΑΠΟΤΕΛΕΣΜΑΤΑ ΚΑΙ ΣΥΜΠΕΡΑΣΜΑΤΑ

Μετά από 20 τρεξίματα του προγράμματος για κάθε ζητούμενη τιμή του M έχουμε τα παρακάτω αποτελέσματα:

- $M = 4$

Μικρότερο σφάλμα ομαδοποίησης: 188.24539841333396


Κέντρα:

(-1.42025, 0.22900000000000015)

(-0.3499607843137255, 0.5894784313725494)

(-1.6738554216867476, 1.4103935742971894)

(-0.6162382812499996, 1.7771328125000005)



Εικόνα 3.1: Γράφημα παραδειγμάτων με 4 κέντρα

- $M = 6$

Μικρότερο σφάλμα ομαδοποίησης: 109.71678634981203


Κέντρα:

(-0.3215675675675676, 1.794222972972972)

(-0.46447761194029846, 0.9800597014925375)

(-1.4276071428571426, 1.7841250000000002)

(-1.4061974789915963, 0.21635714285714305)
(-0.2283902439024391, 0.20921951219512178)
(-1.5959699248120307, 1.0350902255639098)




- $M = 8$

Μικρότερο σφάλμα ομαδοποίησης: 39.569608135682955

Κέντρα:

(-1.7893247863247865, 1.7795470085470086)
(-0.45477099236641216, 0.9842748091603055)
(-0.2066610169491526, 0.2083644067796609)
(-0.22498373983739836, 1.7999593495934956)
(-1.7658617886178856, 0.21160162601626029)
(-1.5889230769230775, 1.0261076923076924)
(-1.0072131147540981, 0.22706557377049175)
(-1.007507352941176, 1.7732279411764704)




Εικόνα 3.3: Γράφημα παραδειγμάτων με 8 κέντρα

- $M = 10$

Μικρότερο σφάλμα ομαδοποίησης: 34.7526809132141

Κέντρα:

(-0.210864406779661, 1.7967542372881349)
(-0.20817241379310347, 0.20094827586206887)
(-0.8558064516129034, 1.8217580645161293)
(-1.10373417721519, 1.746746835443038)
(-0.33402439024390257, 0.9689390243902438)
(-1.5928837209302331, 1.02584496124031)
(-1.7658617886178856, 0.21160162601626029)
(-0.6503018867924528, 1.002320754716981)
(-1.7926120689655176, 1.7801982758620691)
(-1.0072131147540981, 0.22706557377049175)




- $M = 12$


Μικρότερο σφάλμα ομαδοποίησης: 31.075264215713492

Κέντρα:

(-0.21657746478873244, 0.11457746478873244)
(-0.19064583333333332, 0.36762500000000004)
(-0.66650000000000002, 0.99335416666666663)
(-0.8558064516129034, 1.8217580645161293)
(-1.5953046875000008, 1.0284296875)
(-1.1118666666666666, 0.38235555555555556)
(-0.3481084337349399, 0.9924096385542169)
(-0.9578765432098763, 0.14944444444444446)
(-1.771347107438016, 0.20799173553719022)
(-1.7926120689655176, 1.7801982758620691)
(-1.10373417721519, 1.746746835443038)
(-0.210864406779661, 1.7967542372881349)



Εικόνα 3.5: Γράφημα παραδειγμάτων με 12 κέντρα



Εικόνα 3.6: Διάγραμμα σφάλματος ομαδοποίησης συναρτήσει του αριθμού ομάδων

Το σφάλμα ομαδοποίησης δεν είναι καλό κριτήριο για να εκτιμήσουμε τον πραγματικό αριθμό ομάδων. Παρατηρούμε ότι το σφάλμα μειώνεται συνεχώς και για τα πειράματά μας στις 12 ομάδες έχει την ελάχιστη τιμή, όμως γνωρίζουμε ότι ο σωστός αριθμός ομάδων για το παρών πρόβλημα είναι 8.